

Klasyfikacja

Metody Analizy Danych - zadanie projektowe 2

Joanna Dagil (231008), Liliana Grześkiewicz (236138), Piotr Szpatuśko (223420),
Adam Włodarski (230983)

rok akademicki 2025/2026

Spis treści

Streszczenie	2
1 Wstęp	3
2 Przedmiot badania	4
2.1 Cel i zakres badania	4
2.2 Wstępna analiza danych	4
2.2.1 Zmienne wybrane do analizy	4
2.2.2 Statystyki opisowe i podstawowa wizualizacja	4
2.2.3 Transformacje Danych	5
2.2.4 Braki Danych	5
2.2.5 Obserwacje odstające	5
3 Opis metod	6
3.1 Wielomianowa regresja logistyczna	6
3.2 LDA - Linear Discriminant Analysis	6
3.3 QDA - Quadratic Discriminant Analysis	6
3.4 Naive Bayes	6
3.5 Random Forest	6
3.6 SVM - metoda wektorów nośnych	6
3.7 Przegląd literatury dotyczącej metod	6
4 Wyniki	7
4.1 Mierniki	7
4.2 Sposób walidacji	7
5 Przykład użycia modeli na stworzonych sztucznie obserwacjach	8

Streszczenie

Słowa kluczowe: klasyfikacja wieloetykietowa

Rozdział 1

Wstęp

Rozdział 2

Przedmiot badania

2.1 Cel i zakres badania

2.2 Wstępna analiza danych

2.2.1 Zmienne wybrane do analizy

2.2.2 Statystyki opisowe i podstawowa wizualizacja

Tabela 2.1: Statystyki opisowe zmiennych numerycznych

Zmienna	Srednia	Mediana	Minimum	Maksimum	OdchylenieStandardowe	Skosnosc
Area	53048.2845	44652.0000	20420.0000	254616.0000	29324.0957	2.9526
Perimeter	855.2835	794.9410	524.7360	1985.3700	214.2897	1.6259
MajorAxisLength	320.1419	296.8834	183.6012	738.8602	85.6942	1.3577
MinorAxisLength	202.2707	192.4317	122.5127	460.1985	44.9701	2.2380
AspectRatio	1.5832	1.5511	1.0249	2.4303	0.2467	0.5825
Eccentricity	0.7509	0.7644	0.2190	0.9114	0.0920	-1.0627
ConvexArea	53768.2002	45178.0000	20684.0000	263261.0000	29774.9158	2.9415
EquivDiameter	253.0642	238.4380	161.2438	569.3744	59.1771	1.9487
Extent	0.7497	0.7599	0.5553	0.8662	0.0491	-0.8952
Solidity	0.9871	0.9883	0.9192	0.9947	0.0047	-2.5498
roundness	0.8733	0.8832	0.4896	0.9907	0.0595	-0.6357
Compactness	0.7999	0.8013	0.6406	0.9873	0.0617	0.0371
ShapeFactor1	0.0066	0.0066	0.0028	0.0105	0.0011	-0.5341
ShapeFactor2	0.0017	0.0017	0.0006	0.0037	0.0006	0.3012
ShapeFactor3	0.6436	0.6420	0.4103	0.9748	0.0990	0.2425
ShapeFactor4	0.9951	0.9964	0.9477	0.9997	0.0044	-2.7592

Tabela 2.2: Liczebności dla zmiennej Class

Class	liczebność
BARBUNYA	1322
BOMBAY	522
CALI	1630
DERMASON	3546
HOROZ	1928
SEKER	2027
SIRA	2636

2.2.3 Transformacje Danych

2.2.4 Braki Danych

2.2.5 Obserwacje odstające

Rozdział 3

Opis metod

3.1 Wielomianowa regresja logistyczna

Zakłada, że cechy są niezależne, a w wybranym zbiorze takie nie są.

"The multinomial logistic model assumes that data are case-specific; that is, each independent variable has a single value for each case. As with other types of regression, there is no need for the independent variables to be statistically independent from each other (unlike, for example, in a naive Bayes classifier); however, collinearity is assumed to be relatively low, as it becomes difficult to differentiate between the impact of several variables if this is not the case."wtf

3.2 LDA - Linear Discriminant Analysis

3.3 QDA - Quadratic Discriminant Analysis

3.4 Naive Bayes

Zakłada, że cechy są niezależne, a w wybranym zbiorze takie nie są.

3.5 Random Forest

3.6 SVM - metoda wektorów nośnych

3.7 Przegląd literatury dotyczącej metod

Rozdział 4

Wyniki

4.1 Mierniki

4.2 Sposób walidacji

Rozdział 5

Przykład użycia modeli na stworzonych sztucznie obserwacjach

Bibliografia

[1] xx, x. (xxx). *xxx*. xxx. xxxx