

Klasyfikacja

Metody Analizy Danych - zadanie projektowe 2

Joanna Dagil (231008), Liliana Grześkiewicz (236138), Piotr Szpatuśko (223420),
Adam Włodarski (230983)

rok akademicki 2025/2026

Spis treści

Streszczenie	2
1 Wstęp	3
2 Przedmiot badania	4
2.1 Cel i zakres badania	4
2.2 Wstępna analiza danych	4
2.2.1 Zmienne wybrane do analizy	4
2.2.2 Statystyki opisowe i podstawowa wizualizacja	5
2.2.3 Transformacje danych	5
2.2.4 Braki danych	6
2.2.5 Obserwacje odstające	6
2.2.6 Statystyki opisowe i podstawowa wizualizacja	7
2.2.7 Transformacje Danych	7
3 Opis metod	9
3.1 Wielomianowa regresja logistyczna	9
3.2 Random Forest	10
3.3 Sieć neuronowa	10
3.4 Metoda hybrydowa	10
3.5 Przegląd literatury dotyczącej metod	11
4 Wyniki	12
4.1 Mierniki	12
4.2 Sposób walidacji	13
4.3 Wielomianowa regresja logistyczna	13
4.4 Sieć neuronowa	14
4.5 Las losowy (Random Forest)	16
4.6 Metoda hybrydowa	17
5 Przykład użycia modeli na stworzonych sztucznie obserwacjach	19

Streszczenie

Repo:

<https://github.com/joannadagil/DataAnalysisMethods-Classification.git>

Dane:

<https://archive.ics.uci.edu/dataset/602/dry+bean+dataset>

Słowa kluczowe: klasyfikacja wieloklasowa

Rozdział 1

Wstęp

Rozdział 2

Przedmiot badania

2.1 Cel i zakres badania

Głównym celem niniejszego badania jest wielowymiarowa analiza porównawcza oraz klasyfikacja siedmiu różnych odmian fasoli (*BARBUNYA*, *BOMBAY*, *CALI*, *DERMASON*, *HOROZ*, *SEKER* oraz *SIRA*) na podstawie ich cech geometrycznych i morfologicznych. Badanie ma na celu sprawdzenie, w jakim stopniu parametry kształtu oraz wymiary liniowe wyekstrahowane za pomocą technik przetwarzania obrazu pozwalają na bezbłędne przypisanie ziaren do odpowiednich klas botanicznych, co mogłoby zautomatyzować i zobjektywizować proces kontroli jakości w przemyśle spożywczym.

Zakres badania obejmuje:

- Przygotowanie danych, w tym analizę struktur korelacji, identyfikację obserwacji odstających oraz transformację zmiennych w celu spełnienia założeń klasycznych modeli statystycznych.
- Wybór optymalnego podzbioru 12 cech geometrycznych, charakteryzujących zarówno wielkość, jak i unikalny zarys ziaren.
- Budowę i estymację parametrów klasycznych klasyfikatorów probabilistycznych i dyskryminacyjnych (regresja logistyczna, LDA, QDA, Naive Bayes).
- Implementację zaawansowanych algorytmów uczenia maszynowego (Random Forest, SVM) oraz próbę ich integracji w model hybrydowy.
- Ewaluację i porównanie jakości predykcyjnej modeli na podstawie wieloklasowych miar dopasowania, ze szczególnym uwzględnieniem dokładności (*Accuracy*).

2.2 Wstępna analiza danych

Wstępna analiza danych stanowi kluczowy etap procesu modelowania, pozwalający na zrozumienie struktury zbioru, rozkładu poszczególnych cech oraz powiązań pomiędzy nimi. Zbiór danych *Dry Bean Dataset* cechuje się wysoką jakością pomiarów, jednak z uwagi na fizyczną naturę obiektów (wymiary ziaren), zmienne charakteryzują się zróżnicowanymi rzędami wielkości oraz silnymi współzależnościami liniowymi.

2.2.1 Zmienne wybrane do analizy

Zgodnie z wymaganiami projektowymi, z oryginalnego zestawu danych wyselekcjonowano 12 ciągłych zmiennych numerycznych. Zostały one podzielone na dwie grupy: zmienne gabarytowe (opisujące bezwzględny rozmiar) oraz bezwymiarowe współczynniki kształtu (opisujące geometrię i proporcje ziaren). Szczegółowe zestawienie oraz interpretację fizyczną wybranych cech przedstawiono w tabeli 2.1.

Tabela 2.1: Zestawienie i opis zmiennych geometrycznych wybranych do analizy

Nazwa zmiennej	Kategoria cechy	Opis matematyczny / fizyczny
<i>Area</i>	Gabarytowa (Rozmiar)	Pole powierzchni ziarna w pikselach
<i>Perimeter</i>	Gabarytowa (Rozmiar)	Całkowity obwód zewnętrznej granicy
<i>MajorAxisLength</i>	Gabarytowa (Rozmiar)	Długość osi głównej elipsy równoważnej
<i>MinorAxisLength</i>	Gabarytowa (Rozmiar)	Długość osi małej elipsy równoważnej
<i>ConvexArea</i>	Gabarytowa (Rozmiar)	Pole powierzchni najmniejszego wielokąta wypukłego
<i>EquivDiameter</i>	Gabarytowa (Rozmiar)	Średnica koła o polu równym polu ziarna
<i>Eccentricity</i>	Kształt (Proporcje)	Mimośród elipsy (miara wydłużenia obiektu)
<i>Roundness</i>	Kształt (Proporcje)	Współczynnik zaokrąglenia i gładkości brzegu
<i>Compactness</i>	Kształt (Proporcje)	Zwartość (<i>EquivDiameter</i> / <i>MajorAxisLength</i>)
<i>Solidity</i>	Kształt (Proporcje)	Solidność (stosunek <i>Area</i> do <i>ConvexArea</i>)
<i>AspectRatio</i>	Kształt (Proporcje)	Współczynnik proporcji osi głównej do małej
<i>Extent</i>	Kształt (Proporcje)	Stosunek pola powierzchni do prostokąta otaczającego

2.2.2 Statystyki opisowe i podstawowa wizualizacja

W celu ilościowego opisu wybranych zmiennych wyznaczono podstawowe charakterystyki rozkładu empirycznego dla całego zbioru danych. Wyniki zestawiono w tabeli 2.2.

Tabela 2.2: Statystyki opisowe wybranych zmiennych numerycznych dla zbioru Dry Bean

Zmienna	Średnia	Mediana	Min.	Maks.	Odch. std.	Skośność
<i>Area</i>	53048.2	44652.0	20420.0	254616.0	29324.1	2.95
<i>Perimeter</i>	855.2	794.9	524.7	1985.4	214.3	1.63
<i>MajorAxisLength</i>	320.1	296.8	183.6	738.9	85.7	1.36
<i>MinorAxisLength</i>	202.3	192.3	122.5	460.2	45.0	2.23
<i>ConvexArea</i>	53768.2	45170.0	20684.0	263261.0	29774.9	2.94
<i>EquivDiameter</i>	253.1	238.5	161.3	569.4	59.2	1.87
<i>Eccentricity</i>	0.751	0.764	0.219	0.912	0.092	-1.06
<i>Roundness</i>	0.873	0.883	0.489	0.990	0.060	-1.41
<i>Compactness</i>	0.800	0.801	0.641	0.987	0.062	-0.04
<i>Solidity</i>	0.987	0.988	0.911	0.994	0.005	-2.57
<i>AspectRatio</i>	1.583	1.551	1.024	2.430	0.247	0.78
<i>Extent</i>	0.750	0.753	0.555	0.866	0.049	-0.90

Analiza statystyk opisowych wskazuje na występowanie silnej asymetrii prawostronnej w przypadku zmiennych gabarytowych (np. *Area*, *ConvexArea*), co wyraźnie obrazuje dodatnia, wysoka wartość współczynnika skośności. Wynika to bezpośrednio z obecności odmiany *BOMBAY*, której ziarna są wielokrotnie większe od pozostałych gatunków. Wizualizacja rozkładów za pomocą wykresów pudełkowych (ang. *boxplots*) oraz histogramów potwierdza, że odmiany różnią się drastycznie rozrzutem cech rozmiarowych, podczas gdy cechy kształtu (np. *Solidity*, *Roundness*) wykazują rozkłady bardziej skupione wokół swoich wartości centralnych, wykazując najczęściej asymetrię lewostronną.

2.2.3 Transformacje danych

Z uwagi na fakt, że cechy gabarytowe przyjmują wartości rzędu dziesiątek tysięcy, a bezwymiarowe współczynniki kształtu mieszczą się w wąskim przedziale (0, 1), bezpośrednie zastosowanie metod opartych na odległościach lub analizie kowariancji mogłoby prowadzić do dominacji zmiennych o największej skali wartości. W celu ujednolicenia wpływu wszystkich cech na proces klasyfikacji przeprowadzono preprocessing danych obejmujący transformację logarytmiczną oraz standaryzację.

W pierwszym etapie przeanalizowano asymetrię rozkładów wszystkich wybranych zmiennych numerycznych za pomocą współczynnika skośności. Zmienne charakteryzujące się wysoką asymetrią prawostronną, w szczególności zmienne gabarytowe takie jak *Area*, *ConvexArea*, *Perimeter*, *MajorAxisLength*,

`MinorAxisLength` oraz `EquivDiameter`, zostały poddane transformacji logarytmicznej, co pozwoliło ograniczyć wpływ wartości ekstremalnych oraz zmniejszyć asymetrię rozkładów.

Następnie zastosowano procedurę usuwania obserwacji odstających opisaną w kolejnym podrozdziale. Standaryzację danych przeprowadzono dopiero na etapie końcowym, już po oczyszczeniu zbioru, poprzez centrowanie i skalowanie cech numerycznych.

Dzięki temu każda zmienna w końcowym zbiorze uzyskała średnią równą 0 oraz odchylenie standardowe równe 1, co jest zgodne z definicją standaryzacji Z-score.

Standaryzacja była szczególnie istotna z punktu widzenia metod takich jak SVM, LDA oraz QDA, które są wrażliwe na różnice skali pomiędzy zmiennymi oraz strukturę macierzy kowariancji.

2.2.4 Braki danych

Wybrany zbiór danych został otrzymany przez wykorzystanie wizji komputerowej zautomatycznie uzyskującej ze zdjęć komplet wszystkich cech. W otrzymanych danych nie występują więc żadne braki. Dodatkowo poddano weryfikacji pod kątem występowania brakujących wartości. Potwierdzono kompletność cech we wszystkich pozycjach, co eliminuje konieczność stosowania imputacji.

2.2.5 Obserwacje odstające

Fizyczna natura obiektów biologicznych dopuszcza występowanie anomalii rozwojowych, takich jak ziarna uszkodzone mechanicznie, zdeformowane lub niepoprawnie wysegmentowane podczas przetwarzania obrazu. W celu identyfikacji obserwacji odstających zastosowano dwa niezależne podejścia: regułę 1.5 IQR oraz odległość Mahalanobisa.

W pierwszym etapie dla każdej zmiennej numerycznej wyznaczono granice:

$$[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$$

gdzie $Q1$ i $Q3$ oznaczają kwantyle, a IQR rozstęp międzykwantylowy. Obserwacje poza tym zakresem uznano za odstające w ujęciu jednowymiarowym.

W drugim etapie zastosowano analizę wielowymiarową opartą na odległości Mahalanobisa. Ze względu na silne korelacje między zmiennymi macierz kowariancji była bliska osobliwej, dlatego zastosowano jej regularizację poprzez dodanie małej wartości do przekątnej.

Za obserwacje odstające uznano rekordy wskazane przez co najmniej jedną metodę. Następnie zostały one usunięte ze zbioru danych.

2.2.6 Statystyki opisowe i podstawowa wizualizacja

Tabela 2.3: Statystyki opisowe zmiennych numerycznych


Zmienna	Srednia	Mediana	Minimum	Maksimum	OdchylenieStandardowe	Skosnosc
Area	53048.2845	44652.0000	20420.0000	254616.0000	29324.0957	2.9526
Perimeter	855.2835	794.9410	524.7360	1985.3700	214.2897	1.6259
MajorAxisLength	320.1419	296.8834	183.6012	738.8602	85.6942	1.3577
MinorAxisLength	202.2707	192.4317	122.5127	460.1985	44.9701	2.2380
AspectRatio	1.5832	1.5511	1.0249	2.4303	0.2467	0.5825
Eccentricity	0.7509	0.7644	0.2190	0.9114	0.0920	-1.0627
ConvexArea	53768.2002	45178.0000	20684.0000	263261.0000	29774.9158	2.9415
EquivDiameter	253.0642	238.4380	161.2438	569.3744	59.1771	1.9487
Extent	0.7497	0.7599	0.5553	0.8662	0.0491	-0.8952
Solidity	0.9871	0.9883	0.9192	0.9947	0.0047	-2.5498
roundness	0.8733	0.8832	0.4896	0.9907	0.0595	-0.6357
Compactness	0.7999	0.8013	0.6406	0.9873	0.0617	0.0371
ShapeFactor1	0.0066	0.0066	0.0028	0.0105	0.0011	-0.5341
ShapeFactor2	0.0017	0.0017	0.0006	0.0037	0.0006	0.3012
ShapeFactor3	0.6436	0.6420	0.4103	0.9748	0.0990	0.2425
ShapeFactor4	0.9951	0.9964	0.9477	0.9997	0.0044	-2.7592

Tabela 2.4: Liczebności dla zmiennej Class

Class	liczebność
BARBUNYA	1322
BOMBAY	522
CALI	1630
DERMASON	3546
HOROZ	1928
SEKER	2027
SIRA	2636

2.2.7 Transformacje Danych

Dane zostały następnie podzielone na zbiory testowe i treningowe z zachowaniem proporcji klas.



Rysunek 2.1: Porównanie proporcji klas w całym zbiorze danych, zbiorze uczącym i zbiorze testowym.

Następnie zmienne numeryczne zostały przeskalowane oddzielnie dla zbioru uczącego i testowego, z wykorzystaniem parametrów ze zbioru uczącego.

Tabela 2.5: Statystyki opisowe zmiennych numerycznych dla zbioru uczącego (po skalowaniu)

Zmienna	Srednia	Mediana	Minimum	Maksimum	OdchylenieStandardowe	Skosnosc
Area	0	-0.1845	-1.9740	3.9480	1	1.0687
Perimeter	0	-0.2083	-1.9426	3.6920	1	0.8440
MajorAxisLength	0	-0.1836	-1.8799	3.4928	1	0.6305
MinorAxisLength	0	-0.1609	-2.0683	4.1521	1	1.3278
ConvexArea	0	-0.1860	-1.9662	3.9365	1	1.0637
EquivDiameter	0	-0.1845	-1.9740	3.9480	1	1.0687
Eccentricity	0	0.1889	-4.0228	1.4940	1	-1.3273
roundness	0	0.1734	-3.2286	2.0258	1	-0.4509
Compactness	0	0.0228	-2.4068	2.4175	1	0.0024
Solidity	0	0.2043	-5.0860	1.9665	1	-1.3604
AspectRatio	0	-0.1294	-1.9261	3.0375	1	0.6072
Extent	0	0.2060	-3.7066	2.3662	1	-0.9049

Rozdział 3

Opis metod

W niniejszym rozdziale przedstawiono metody klasyfikacji wykorzystane do rozwiązania problemu przypisania ziaren fasoli do odpowiednich odmian. Analizowany problem ma charakter klasyfikacji wieloklasowej, ponieważ zmienna objaśniana może przyjmować więcej niż dwie możliwe wartości.

Niech zmienna objaśniana Y oznacza klasę, czyli odmianę fasoli. W zbiorze *Dry Bean Dataset* zmienna ta przyjmuje jedną z siedmiu wartości:

$$Y \in \{SEKER, BARBUNYA, BOMBAY, CALI, DERMASON, HOROZ, SIRA\}.$$

Zmiennymi objaśniającymi są cechy geometryczne i morfologiczne opisujące pojedyncze ziarno fasoli. Dla pojedynczej obserwacji można je zapisać w postaci wektora:

$$X = (X_1, X_2, \dots, X_p),$$

gdzie p oznacza liczbę zmiennych objaśniających uwzględnionych w analizie.

Celem każdej z zastosowanych metod jest wyznaczenie reguły klasyfikacyjnej, która na podstawie wartości cech X przypisuje obserwację do jednej z klas Y . Innymi słowy, dla każdego ziarna fasoli model podejmuje decyzję, do której odmiany jest ono najbardziej podobne ze względu na swoje cechy geometryczne.

W analizie wykorzystano zmienne opisujące między innymi rozmiar, kształt, wydłużenie oraz regularność ziarna. Do cech związanych z rozmiarem należą na przykład *Area*, *Perimeter*, *ConvexArea*, *MajorAxisLength* oraz *MinorAxisLength*. Z kolei cechy takie jak *Eccentricity*, *Roundness*, *Compactness*, *AspectRatio* czy *Solidity* opisują przede wszystkim kształt i proporcje ziarna.

Zastosowane metody różnią się sposobem wyznaczania granic decyzyjnych między klasami. Część z nich, na przykład wielomianowa regresja logistyczna oraz LDA, zakłada liniowy charakter granic między klasami. Inne, takie jak QDA, drzewa decyzyjne, Random Forest czy SVM, pozwalają na bardziej złożone granice decyzyjne. Dzięki temu możliwe jest porównanie zarówno prostszych, bardziej interpretowalnych metod statystycznych, jak i metod bardziej elastycznych.

W dalszej części rozdziału opisano kolejno zastosowane metody klasyfikacji oraz sposób podejmowania przez nie decyzji klasyfikacyjnych.

3.1 Wielomianowa regresja logistyczna

Wielomianowa regresja logistyczna jest rozszerzeniem klasycznej regresji logistycznej na przypadek, w którym zmienna objaśniana przyjmuje więcej niż dwie kategorie. W analizowanym problemie metoda ta służy do oszacowania prawdopodobieństwa przynależności ziarna fasoli do każdej z rozważanych odmian.

Celem wielomianowej regresji logistycznej jest oszacowanie prawdopodobieństwa przynależności obserwacji do każdej z możliwych klas. Dla każdej obserwacji model wyznacza prawdopodobieństwa:

$$P(Y = k | X),$$

gdzie k oznacza jedną z klas. Obserwacja zostaje następnie przypisana do tej klasy, dla której przewidywane prawdopodobieństwo jest największe.

W modelu wielomianowej regresji logistycznej jedna z klas jest wybierana jako klasa referencyjna. Dla pozostałych klas modeluje się logarytm ilorazu szans względem tej klasy. Jeżeli jako klasę referencyjną oznaczymy klasę K , to dla każdej klasy $k = 1, \dots, K - 1$ model ma postać:

$$\log \left(\frac{P(Y = k | X)}{P(Y = K | X)} \right) = \beta_{0k} + \beta_{1k}X_1 + \beta_{2k}X_2 + \dots + \beta_{pk}X_p.$$

Oznacza to, że dla każdej klasy, z wyjątkiem klasy referencyjnej, estymowany jest osobny zestaw współczynników regresji. Współczynniki te opisują wpływ poszczególnych cech ziarna na względne prawdopodobieństwo przypisania obserwacji do danej klasy w porównaniu z klasą referencyjną.

Prawdopodobieństwa przynależności do poszczególnych klas można zapisać w postaci:

$$P(Y = k | X) = \frac{\exp(\beta_{0k} + \beta_{1k}X_1 + \dots + \beta_{pk}X_p)}{1 + \sum_{j=1}^{K-1} \exp(\beta_{0j} + \beta_{1j}X_1 + \dots + \beta_{pj}X_p)}$$

dla $k = 1, \dots, K - 1$, natomiast dla klasy referencyjnej:

$$P(Y = K | X) = \frac{1}{1 + \sum_{j=1}^{K-1} \exp(\beta_{0j} + \beta_{1j}X_1 + \dots + \beta_{pj}X_p)}.$$

W kontekście analizowanego zbioru danych model ten pozwala określić, jak cechy geometryczne ziarna wpływają na prawdopodobieństwo zaklasyfikowania go do konkretnej odmiany fasoli. Przykładowo, cechy związane z rozmiarem ziarna, takie jak *Area*, *Perimeter* czy *MajorAxisLength*, mogą mieć istotne znaczenie przy rozróżnianiu większych odmian fasoli od mniejszych. Z kolei cechy opisujące kształt, takie jak *Roundness*, *Compactness* czy *Eccentricity*, mogą pomagać w odróżnianiu odmian bardziej okrągłych od bardziej wydłużonych.

Klasyfikacja nowej obserwacji odbywa się poprzez obliczenie przewidywanego prawdopodobieństwa dla każdej klasy i wybór klasy o największej wartości tego prawdopodobieństwa:

$$\hat{Y} = \arg \max_k P(Y = k | X).$$

Wielomianowa regresja logistyczna jest metodą parametryczną i stosunkowo łatwą do interpretacji. Jej zaletą jest możliwość uzyskania nie tylko przewidywanej klasy, ale również prawdopodobieństw przynależności do każdej z klas. Dzięki temu można analizować, z jaką pewnością model przypisuje dane ziarno do konkretnej odmiany.

Metoda ta zakłada jednak, że zależność pomiędzy zmiennymi objaśniającymi a logarytmem ilorazu szans jest liniowa. W praktyce oznacza to, że model może gorzej radzić sobie w sytuacjach, gdy granice między klasami mają silnie nieliniowy charakter. W przypadku zbioru *Dry Bean* może to mieć znaczenie, ponieważ niektóre odmiany fasoli mogą być do siebie bardzo podobne pod względem wybranych cech morfologicznych.

W przeprowadzonej analizie wielomianowa regresja logistyczna została wykorzystana jako jedna z metod klasyfikacji statystycznej. Jej wyniki porównano z wynikami pozostałych metod na podstawie miar jakości klasyfikacji, takich jak macierz pomyłek, dokładność klasyfikacji oraz miary precyzji, czułości i wyniku F_1 .

3.2 Random Forest

3.3 Sieć neuronowa

3.4 Metoda hybrydowa

Metoda hybrydowa należy do grupy metod zespołowych (ensemble methods), których celem jest połączenie wyników wielu klasyfikatorów w celu poprawy jakości klasyfikacji. W przedstawionym rozwiązaniu wykorzystano trzy wcześniej zbudowane modele: wielomianową regresję logistyczną, las losowy (Random Forest) oraz sieć neuronową.

Każdy z modeli generował niezależną predykcję klasy dla obserwacji ze zbioru testowego. Następnie zastosowano mechanizm głosowania większościowego (majority voting). Ostateczną klasę przypisywano na podstawie największej liczby głosów oddanych przez poszczególne modele.

Przykładowo, jeśli dwa spośród trzech klasyfikatorów wskazywały tę samą klasę, była ona przyjmowana jako wynik końcowy. Takie podejście pozwala ograniczyć wpływ błędów pojedynczego modelu oraz zwiększyć stabilność procesu klasyfikacji.

Zastosowanie metody hybrydowej umożliwia wykorzystanie zalet różnych algorytmów. Regresja logistyczna dobrze modeluje zależności liniowe, Random Forest skutecznie identyfikuje zależności nieliniowe i interakcje pomiędzy cechami, natomiast sieci neuronowe pozwalają wykrywać bardziej złożone wzorce występujące w danych. Dzięki temu model zespołowy może osiągać lepsze wyniki niż pojedyncze klasyfikatory.

3.5 Przegląd literatury dotyczącej metod

Problematyka zautomatyzowanej oceny i klasyfikacji produktów rolniczych z wykorzystaniem wizji komputerowej jest intensywnie rozwijana w literaturze naukowej. Sam oryginalny zbiór danych *Dry Bean Dataset* został opracowany i opublikowany w pracy Koklu i Ozkana [?]. Autorzy skutecznie pozyskali parametry morfologiczne z obrazów ziaren, a następnie wykorzystali je do porównania wydajności klasyfikatorów takich jak sztuczne sieci neuronowe (MLP), maszyny wektorów nośnych oraz k-najbliższych sąsiadów. Ich badania dowiodły, że parametry geometryczne są wystarczające do zbudowania wysoce skutecznych modeli różnicujących gatunki fasoli.

Podstawy pod wykorzystane w analizie nowoczesne algorytmy uczenia maszynowego były formowane w pracach kładących podwaliny pod współczesne statystyczne analizy wielowymiarowe. Metoda maszyn wektorów nośnych (SVM) z mechanizmem obsługi danych zaszumionych (tworząca fundamenty sformułowanego w równaniach (3.3)–(3.4) miękkiego marginesu) została sformalizowana w przełomowej pracy Cortesa i Vapnika z 1995 roku [?]. Rozwiązało to problem klasyfikacji zbiorów liniowo nieseparowalnych, co znacząco rozszerzyło dziedziny aplikacji tego modelu. Z kolei idea i ścisły dowód na to, że wstrzykiwanie losowości do zespołów klasyfikatorów znacząco redukuje błąd generalizacji, została opublikowana w kanonicznej już pracy Leo Breimana z 2001 roku [?], wprowadzającej algorytm *Random Forest*.

Użyte jako punkt odniesienia klasyczne metody, takie jak wielomianowa regresja logistyczna oraz analiza dyskryminacyjna, opierają się na dobrze ugruntowanej teorii probabilistycznej i wciąż są powszechnie stosowane w obszarach wymagających bezpośredniej interpretacji estymowanych współczynników wpływu cech na przynależność klasową.

Rozdział 4

Wyniki

4.1 Mierniki

Do oceny jakości klasyfikacji wykorzystano macierz pomyłek, dokładność klasyfikacji (*Accuracy*) oraz miary *Precision*, *Recall* i *F1-score*. Ponieważ analizowane zadanie jest problemem klasyfikacji wieloklasowej, każda obserwacja może zostać przypisana do jednej z siedmiu odmian fasoli. Z tego względu macierz pomyłek ma wymiar $K \times K$, gdzie w rozpatrywanym przypadku $K = 7$. Wiersze macierzy odpowiadają klasom rzeczywistym, natomiast kolumny klasom przewidzianym przez model. Elementy na głównej przekątnej oznaczają obserwacje sklasyfikowane poprawnie, a elementy poza przekątną przedstawiają pomyłki między poszczególnymi klasami.

Dokładność klasyfikacji jest jedną globalną miarą jakości całego modelu. W problemie wieloklasowym oblicza się ją jako udział wszystkich poprawnie sklasyfikowanych obserwacji w całkowitej liczbie obserwacji ze zbioru testowego:

$$Accuracy = \frac{\sum_{k=1}^K n_{kk}}{N}$$

gdzie n_{kk} oznacza liczbę obserwacji klasy k poprawnie przypisanych do tej samej klasy, a N oznacza liczbę wszystkich obserwacji. W liczniku sumowane są zatem elementy znajdujące się na głównej przekątnej macierzy pomyłek. W przedstawionych wynikach nie wyznacza się oddzielnego *Accuracy* dla każdej klasy. Jedna wartość tej miary podsumowuje skuteczność klasyfikatora dla wszystkich siedmiu klas jednocześnie.

Samo *Accuracy* nie pokazuje jednak, dla których odmian model działa dobrze, a dla których popełnia najwięcej błędów. Dlatego dodatkowo obliczono *Precision*, *Recall* oraz *F1-score* osobno dla każdej klasy. W przypadku klasyfikacji wieloklasowej miary te wyznaczono w schemacie jeden-przeciwko-reszcie (*one-vs-rest*). Dla rozpatrywanej klasy k jest ona traktowana jako klasa pozytywna, natomiast wszystkie pozostałe klasy łącznie jako klasa negatywna.

Dla każdej klasy k zdefiniowano:

$$Precision_k = \frac{TP_k}{TP_k + FP_k},$$

$$Recall_k = \frac{TP_k}{TP_k + FN_k},$$

$$F1_k = 2 \cdot \frac{Precision_k \cdot Recall_k}{Precision_k + Recall_k}.$$

Wielkość TP_k oznacza liczbę obserwacji klasy k poprawnie rozpoznanych przez model. FP_k oznacza liczbę obserwacji należących do innych klas, które błędnie przypisano do klasy k , natomiast FN_k oznacza liczbę obserwacji klasy k , które błędnie przypisano do jednej z pozostałych klas. *Precision* określa, jaka część obserwacji przewidzianych jako dana odmiana rzeczywiście do niej należy. *Recall* informuje, jaka część wszystkich rzeczywistych obserwacji danej odmiany została poprawnie rozpoznana. *F1-score* jest średnią harmoniczną tych dwóch miar i uwzględnia jednocześnie oba rodzaje błędów.

Wyniki każdego klasyfikatora przedstawiono zatem na dwóch poziomach. Globalne *Accuracy* służy do ogólnego porównania modeli, natomiast wartości *Precision*, *Recall* i *F1-score* pozwalają ocenić jakość klasyfikacji osobno dla każdej z siedmiu odmian fasoli.

4.2 Sposób walidacji

Do oceny zdolności modeli do klasyfikowania nowych obserwacji zastosowano walidację typu *hold-out*. Polega ona na jednorazowym podziale zbioru danych na rozłączne zbiory: uczący oraz testowy. W przeprowadzonej analizie 70% obserwacji przeznaczono do uczenia modeli, a pozostałe 30% do ich końcowej oceny.

Podział wykonano w sposób stratyfikowany, czyli oddzielnie w obrębie każdej klasy. Dzięki temu w zbiorze uczącym i testowym zachowano proporcje siedmiu odmian fasoli zbliżone do proporcji występujących w całym oczyszczonym zbiorze danych. Jest to szczególnie istotne w analizowanym problemie, ponieważ liczebności poszczególnych klas nie są jednakowe. Dla zapewnienia powtarzalności losowania ustawiono ziarno generatora liczb pseudolosowych na wartość 42.

Zbiór uczący wykorzystano do estymacji parametrów wielomianowej regresji logistycznej, lasu losowego oraz sieci neuronowej. Zbiór testowy nie uczestniczył w procesie uczenia i służył wyłącznie do obliczenia końcowych wartości mierników jakości. Metodę hybrydową oceniono na tym samym zbiorze testowym, łącząc predykcje trzech wcześniej wytrenowanych klasyfikatorów.

Aby uniknąć przenikania informacji ze zbioru testowego do procesu uczenia, parametry standaryzacji, czyli średnie i odchylenia standardowe zmiennych, wyznaczono wyłącznie na podstawie zbioru uczącego. Następnie te same parametry zastosowano do przeskalowania zbioru testowego. Wszystkie modele oceniono na identycznych obserwacjach testowych i przy użyciu tego samego zestawu mierników: macierzy pomyłek, *Accuracy*, *Precision*, *Recall* oraz *F1-score*. Pozwala to na bezpośrednie i porównywalne zestawienie wyników poszczególnych metod.

4.3 Wielomianowa regresja logistyczna

Metryki

Tabela 4.1: Macierz pomyłek dla wielomianowej regresji logistycznej

	BARBUNYA	BOMBAY	CALI	DERMASON	HOROS	SEKER	SIRA
BARBUNYA	340	0	12	0	0	0	1
BOMBAY	0	140	0	0	0	0	0
CALI	13	0	437	0	2	0	0
DERMASON	0	0	0	918	0	10	50
HOROS	1	0	6	0	477	0	2
SEKER	0	0	0	3	0	522	5
SIRA	0	0	0	56	4	3	658

Tabela 4.2: Dokładność klasyfikacji dla wielomianowej regresji logistycznej

Metoda	Accuracy
Wielomianowa regresja logistyczna	0.9541

Tabela 4.3: Miary jakości klasyfikacji dla wielomianowej regresji logistycznej


Klasa	Precision	Recall	F1
BARBUNYA	0.9605	0.9632	0.9618
BOMBAY	1.0000	1.0000	1.0000
CALI	0.9604	0.9668	0.9636
DERMASON	0.9396	0.9387	0.9391
HOROZ	0.9876	0.9815	0.9845
SEKER	0.9757	0.9849	0.9803
SIRA	0.9190	0.9126	0.9158

4.4 Sieć neuronowa

W analizie zastosowano jednokierunkową, wielowarstwową sieć neuronową typu MLP, czyli *Multilayer Perceptron*.

Architektura

Zastosowana sieć składała się z trzech głównych części: warstwy wejściowej, jednej warstwy ukrytej oraz warstwy wyjściowej.



Rysunek 4.1: Schemat architektury zastosowanej sieci neuronowej.

Zastosowana sieć składała się z trzech głównych części: warstwy wejściowej, jednej warstwy ukrytej oraz warstwy wyjściowej. Warstwa wejściowa miała tyle wejść, ile zmiennych objaśniających.

Pomiędzy warstwą wejściową a warstwą wyjściową zastosowano jedną warstwę ukrytą złożoną z 8 neuronów. Liczbę neuronów w tej warstwie określa parametr `size`. W przeprowadzonej analizie przyjęto:

`size = 8.`

Warstwa ukryta umożliwia modelowi uchwycenie nieliniowych zależności między cechami wejściowymi a klasą fasoli. Dzięki temu sieć neuronowa może modelować bardziej złożone granice decyzyjne niż metody liniowe, takie jak wielomianowa regresja logistyczna czy LDA.

W warstwie wyjściowej zastosowano tyle neuronów, ile było klas zmiennej objaśnianej, czyli 7.

Ponieważ analizowany problem jest problemem klasyfikacji wieloklasowej, na warstwie wyjściowej zastosowano funkcję *softmax*. Ostateczna klasyfikacja odbywa się poprzez wybór klasy o największym przewidywanym prawdopodobieństwie.

W modelu zastosowano również regularyzację wag określoną parametrem *decay*. W analizie przyjęto:

$$\text{decay} = 0.001.$$

Regularyzacja ogranicza nadmierny wzrost wartości wag, co zmniejsza ryzyko przeuczenia modelu. Oznacza to, że sieć nie tylko dopasowuje się do danych uczących, ale jest również zachęcana do zachowania prostszej struktury wag.

Proces uczenia sieci polegał na iteracyjnym doborze wag połączeń między neuronami w taki sposób, aby minimalizować błąd klasyfikacji na zbiorze uczącym. Maksymalną liczbę iteracji ustalono na:

$$\text{maxit} = 1000.$$

Dodatkowo parametr *MaxNWts* określał maksymalną dopuszczalną liczbę wag w modelu. W analizie ustawiono:

$$\text{MaxNWts} = 10000,$$

aby uniknąć ograniczeń technicznych związanych z liczbą parametrów sieci.

Metryki

Tabela 4.4: Macierz pomyłek dla sieci neuronowej

	BARBUNYA	BOMBAY	CALI	DERMASON	HOROS	SEKER	SIRA
BARBUNYA	339	0	12	0	0	0	2
BOMBAY	1	139	0	0	0	0	0
CALI	10	0	438	0	3	0	1
DERMASON	0	0	0	923	0	10	45
HOROS	0	0	6	0	476	0	4
SEKER	0	0	0	4	0	523	3
SIRA	5	0	0	62	4	2	648

Tabela 4.5: Dokładność klasyfikacji dla sieci neuronowej

Metoda	Accuracy
Sieć neuronowa	0.9525

Tabela 4.6: Miary jakości klasyfikacji dla sieci neuronowej

Klasa	Precision	Recall	F1
BARBUNYA	0.9549	0.9603	0.9576
BOMBAY	1.0000	0.9929	0.9964
CALI	0.9605	0.9690	0.9648
DERMASON	0.9333	0.9438	0.9385
HOROS	0.9855	0.9794	0.9825
SEKER	0.9776	0.9868	0.9822
SIRA	0.9218	0.8988	0.9101

4.5 Las losowy (Random Forest)

Las losowy (ang. *Random Forest*) stanowi zaawansowaną metodę uczenia zespołowego (ang. *ensemble learning*), łączącą podejście nieparametryczne z dużą elastycznością dopasowania. Algorytm ten bazuje na konstrukcji dużej liczby niezależnych od siebie algorytmów słabych — w tym przypadku pojedynczych drzew decyzyjnych — a następnie agregacji ich predykcji poprzez głosowanie większościowe.

Kluczem do skuteczności lasu losowego jest redukcja wariancji pojedynczych drzew bez jednoczesnego zwiększania ich obciążenia. Cel ten osiągnąć jest poprzez wprowadzenie dwupoziomowej losowości:

1. **Agregacja bootstrapowa (Bagging):** Każde drzewo w zespole trenowane jest na osobnym podzbiórze obserwacji, losowanym ze zwracaniem z oryginalnego zestawu danych treningowych. Obserwacje, które nie zostaną wybrane do próby uczącej danego drzewa, tworzą zbiór *Out-of-Bag* (OOB) i są wykorzystywane do wewnętrznej, bezstronnej oceny błędu generalizacji modelu.
2. **Losowe podprzestrzenie cech (Random Subspace Method):** Podczas podziału węzła w procesie wzrostu drzewa, algorytm nie poszukuje optymalnego podziału spośród wszystkich dostępnych predyktorów. Zamiast tego wybiera losowy podzbiór cech o określonej liczności (standardowo dla klasyfikacji przyjmuje się pierwiastek z łącznej liczby cech). Procedura ta drastycznie zmniejsza skorelowanie poszczególnych drzew w lesie, dzięki czemu błędy pojedynczych klasyfikatorów wzajemnie się znoszą.

Dla wektora cech geometrycznych ziarna, ostateczna decyzja klasyfikacyjna modelu podejmowana jest w oparciu o głosowanie większościowe wszystkich wygenerowanych drzew decyzyjnych. Algorytm pozwala także na precyzyjną ocenę istotności predyktorów w procesie różnicowania odmian fasoli za pomocą miar spadku dokładności klasyfikacji (MDA) oraz spadku nieczystości węzłów mierzony współczynnikiem Giniego (MDG).

Metryki

Ewaluację modelu lasu losowego przeprowadzono na zbiorze testowym przy zachowaniu procedur preprocessingu (skalowanie predyktorów na podstawie parametrów wyznaczonych wyłącznie ze zbioru treningowego). Szczegółowe zestawienie macierzy pomyłek, ogólnej dokładności, miar jakości klasyfikacji dla poszczególnych odmian oraz istotności zmiennych przedstawiono w tabelach poniżej.

Tabela 4.7: Macierz pomyłek dla lasu losowego (Random Forest)

	BARBUNYA	BOMBAY	CALI	DERMASON	HOROS	SEKER	SIRA
BARBUNYA	321	0	28	0	1	1	2
BOMBAY	0	140	0	0	0	0	0
CALI	17	0	433	0	1	0	1
DERMASON	0	0	0	909	0	16	53
HOROS	0	0	7	0	478	0	1
SEKER	0	0	0	6	0	519	5
SIRA	0	0	1	68	2	2	648

Tabela 4.8: Dokładność klasyfikacji dla lasu losowego

Metoda	Accuracy
Random Forest (Las Losowy)	0.9421

Tabela 4.9: Miary jakości klasyfikacji dla lasu losowego dla poszczególnych odmian fasoli

Klasa	Precision	Recall	F1
BARBUNYA	0.9497	0.9093	0.9291
BOMBAY	1.0000	1.0000	1.0000
CALI	0.9232	0.9580	0.9403
DERMASON	0.9247	0.9294	0.9271
HOROS	0.9917	0.9835	0.9876
SEKER	0.9647	0.9792	0.9719
SIRA	0.9127	0.8988	0.9057

Tabela 4.10: Istotność zmiennych w modelu Random Forest

	Zmienna	MeanDecreaseAccuracy	MeanDecreaseGini
Area	Area	29.4617	513.8312
Perimeter	Perimeter	35.8204	835.8412
MajorAxisLength	MajorAxisLength	26.4750	704.3006
MinorAxisLength	MinorAxisLength	42.2704	642.4694
ConvexArea	ConvexArea	32.4801	577.9214
EquivDiameter	EquivDiameter	30.1653	481.1038
Eccentricity	Eccentricity	42.3178	824.7030
roundness	roundness	60.5462	532.0119
Compactness	Compactness	52.2025	933.2403
Solidity	Solidity	35.6554	119.3277
AspectRatio	AspectRatio	40.7116	790.6448
Extent	Extent	15.6149	81.4359

4.6 Metoda hybrydowa

W celu sprawdzenia, czy połączenie kilku klasyfikatorów pozwoli uzyskać lepsze wyniki klasyfikacji, zastosowano metodę hybrydową. Końcowa decyzja klasyfikacyjna była wyznaczana na podstawie głosowania większościowego trzech modeli: wielomianowej regresji logistycznej, lasu losowego oraz sieci neuronowej.

Poniżej przedstawiono wyniki uzyskane przez model hybrydowy na zbiorze testowym. Zaprezentowano macierz pomyłek, dokładność klasyfikacji oraz wartości miar Precision, Recall i F1-score dla poszczególnych klas fasoli.

Tabela 4.11: Macierz pomyłek dla metody hybrydowej

	BARBUNYA	BOMBAY	CALI	DERMASON	HOROS	SEKER	SIRA
BARBUNYA	339	0	12	0	0	0	2
BOMBAY	0	140	0	0	0	0	0
CALI	10	0	439	0	2	0	1
DERMASON	0	0	0	923	0	11	44
HOROS	0	0	6	0	479	0	1
SEKER	0	0	0	4	0	522	4
SIRA	0	0	0	64	3	2	652

Tabela 4.12: Dokładność klasyfikacji dla metody hybrydowej

Metoda	Accuracy
Metoda hybrydowa (Voting Ensemble)	0.9546

Tabela 4.13: Miary jakości klasyfikacji dla metody hybrydowej

Klasa	Precision	Recall	F1
BARBUNYA	0.9713	0.9603	0.9658
BOMBAY	1.0000	1.0000	1.0000
CALI	0.9606	0.9712	0.9659
DERMASON	0.9314	0.9438	0.9375
HOROZ	0.9897	0.9856	0.9876
SEKER	0.9757	0.9849	0.9803
SIRA	0.9261	0.9043	0.9151

Uzyskane wyniki pozwalają ocenić skuteczność podejścia zespołowego oraz porównać je z rezultatami osiągniętymi przez pojedyncze modele przedstawione we wcześniejszych podrozdziałach.

Rozdział 5

Przykład użycia modeli na stworzonych sztucznie obserwacjach

Oprócz oceny modeli na zbiorze testowym przygotowano również krótki przykład użycia klasyfikatorów na obserwacjach sztucznie wygenerowanych. Celem tej części nie jest ponowna walidacja jakości modeli, ponieważ sztuczne obserwacje nie pochodzą z rzeczywistego pomiaru. Przykład pokazuje natomiast, w jaki sposób wytrenowane modele można wykorzystać do klasyfikacji nowych rekordów o znanych wartościach cech geometrycznych.

Sztuczne obserwacje zostały wygenerowane osobno dla każdej odmiany fasoli. Dla każdej klasy wyznaczono średnie oraz odchylenia standardowe cech numerycznych w zbiorze uczącym, a następnie wylosowano przykładowe punkty położone blisko typowych wartości danej klasy. Aby uniknąć tworzenia nierealistycznych rekordów, wartości zostały ograniczone do zakresów obserwowanych w zbiorze uczącym.

Następnie sztuczne dane poddano takiemu samemu przeskalowaniu jak zbiór testowy. Wykorzystano do tego średnie i odchylenia standardowe obliczone wyłącznie na zbiorze uczącym, dzięki czemu zachowano spójność z procedurą preprocessingu zastosowaną przy trenowaniu modeli.

Dla każdej sztucznej obserwacji wykonano predykcję za pomocą czterech podejść: wielomianowej regresji logistycznej, lasu losowego, sieci neuronowej oraz metody hybrydowej. W przypadku metody hybrydowej ostateczna klasa została wyznaczona przez głosowanie większościowe trzech pojedynczych klasyfikatorów.

Tabela 5.1: Predykcje modeli dla sztucznie wygenerowanych obserwacji

Nr	Klasa_bazowa	Regresja_logistyczna	Random_Forest	Siec_neuronowa	Metoda_hybrydowa
1	BARBUNYA	BARBUNYA	BARBUNYA	BARBUNYA	BARBUNYA
2	BARBUNYA	SEKER	BARBUNYA	BARBUNYA	BARBUNYA
3	BOMBAY	BOMBAY	BOMBAY	BOMBAY	BOMBAY
4	BOMBAY	BOMBAY	BOMBAY	BOMBAY	BOMBAY
5	CALI	CALI	CALI	CALI	CALI
6	CALI	CALI	CALI	SIRA	CALI
7	DERMASON	DERMASON	DERMASON	DERMASON	DERMASON
8	DERMASON	SEKER	DERMASON	DERMASON	DERMASON
9	HOROS	HOROS	HOROS	HOROS	HOROS
10	HOROS	HOROS	HOROS	HOROS	HOROS
11	SEKER	SEKER	SEKER	DERMASON	SEKER
12	SEKER	SEKER	SEKER	SEKER	SEKER
13	SIRA	CALI	SIRA	SIRA	SIRA
14	SIRA	HOROS	SIRA	SIRA	SIRA

W tabeli kolumna *Klasa bazowa* oznacza klasę, na podstawie której wygenerowano daną sztuczną obserwację. Nie jest to rzeczywista etykieta pomiarowa, lecz punkt odniesienia pozwalający sprawdzić,

czy modele przypisują wygenerowane obserwacje do klas zgodnych z ich konstrukcją. Zgodność predykcji z klasą bazową sugeruje, że model poprawnie rozpoznaje typowe układy cech charakterystyczne dla danej odmiany fasoli.

Bibliografia

- [1] Koklu, x. (xxx). *xxx*. xxx. xxxx
- [2] Cortes, x. (xxx). *xxx*. xxx. xxxx
- [3] Breiman, x. (xxx). *xxx*. xxx. xxxx