

Klasyfikacja

Metody Analizy Danych - zadanie projektowe 2

Joanna Dagil (231008), Liliana Grześkiewicz (236138), Piotr Szpatuśko (223420),
Adam Włodarski (230983)

rok akademicki 2025/2026

Spis treści

Streszczenie	2
1 Wstęp	3
2 Przedmiot badania	4
2.1 Cel i zakres badania	4
2.2 Wstępna analiza danych	4
2.2.1 Zmienne wybrane do analizy	4
2.2.2 Statystyki opisowe i podstawowa wizualizacja	5
2.2.3 Transformacje danych	5
2.2.4 Braki danych	6
2.2.5 Obserwacje odstające	6
3 Opis metod	7
3.1 Wielomianowa regresja logistyczna	7
3.2 LDA - Linear Discriminant Analysis	8
3.3 QDA - Quadratic Discriminant Analysis	9
3.4 Naive Bayes	10
3.5 Random Forest	11
3.6 SVM - metoda wektorów nośnych	12
3.7 Przegląd literatury dotyczącej metod	12
4 Wyniki	14
4.1 Mierniki	14
4.2 Sposób walidacji	14
5 Przykład użycia modeli na stworzonych sztucznie obserwacjach	15

Streszczenie

Repo:

<https://github.com/joannadagil/DataAnalysisMethods-Classification.git>

Dane:

<https://archive.ics.uci.edu/dataset/602/dry+bean+dataset>

Słowa kluczowe: klasyfikacja wieloklasowa

Rozdział 1

Wstęp

Rozdział 2

Przedmiot badania

2.1 Cel i zakres badania

Głównym celem niniejszego badania jest wielowymiarowa analiza porównawcza oraz klasyfikacja siedmiu różnych odmian fasoli (*BARBUNYA*, *BOMBAY*, *CALI*, *DERMASON*, *HOROZ*, *SEKER* oraz *SIRA*) na podstawie ich cech geometrycznych i morfologicznych. Badanie ma na celu sprawdzenie, w jakim stopniu parametry kształtu oraz wymiary liniowe wyekstrahowane za pomocą technik przetwarzania obrazu pozwalają na bezbłędne przypisanie ziaren do odpowiednich klas botanicznych, co mogłoby zautomatyzować i zobjektywizować proces kontroli jakości w przemyśle spożywczym.

Zakres badania obejmuje:

- Przygotowanie danych, w tym analizę struktur korelacji, identyfikację obserwacji odstających oraz transformację zmiennych w celu spełnienia założeń klasycznych modeli statystycznych.
- Wybór optymalnego podzbioru 12 cech geometrycznych, charakteryzujących zarówno wielkość, jak i unikalny zarys ziaren.
- Budowę i estymację parametrów klasycznych klasyfikatorów probabilistycznych i dyskryminacyjnych (regresja logistyczna, LDA, QDA, Naive Bayes).
- Implementację zaawansowanych algorytmów uczenia maszynowego (Random Forest, SVM) oraz próbę ich integracji w model hybrydowy.
- Ewaluację i porównanie jakości predykcyjnej modeli na podstawie wieloklasowych miar dopasowania, ze szczególnym uwzględnieniem dokładności (*Accuracy*).

2.2 Wstępna analiza danych

Wstępna analiza danych stanowi kluczowy etap procesu modelowania, pozwalający na zrozumienie struktury zbioru, rozkładu poszczególnych cech oraz powiązań pomiędzy nimi. Zbiór danych *Dry Bean Dataset* cechuje się wysoką jakością pomiarów, jednak z uwagi na fizyczną naturę obiektów (wymiary ziaren), zmienne charakteryzują się zróżnicowanymi rzędami wielkości oraz silnymi współzależnościami liniowymi.

2.2.1 Zmienne wybrane do analizy

Zgodnie z wymaganiami projektowymi, z oryginalnego zestawu danych wyselekcjonowano 12 ciągłych zmiennych numerycznych. Zostały one podzielone na dwie grupy: zmienne gabarytowe (opisujące bezwzględny rozmiar) oraz bezwymiarowe współczynniki kształtu (opisujące geometrię i proporcje ziaren). Szczegółowe zestawienie oraz interpretację fizyczną wybranych cech przedstawiono w tabeli 2.1.

Tabela 2.1: Zestawienie i opis zmiennych geometrycznych wybranych do analizy

Nazwa zmiennej	Kategoria cechy	Opis matematyczny / fizyczny
<i>Area</i>	Gabarytowa (Rozmiar)	Pole powierzchni ziarna w pikselach
<i>Perimeter</i>	Gabarytowa (Rozmiar)	Całkowity obwód zewnętrznej granicy
<i>MajorAxisLength</i>	Gabarytowa (Rozmiar)	Długość osi głównej elipsy równoważnej
<i>MinorAxisLength</i>	Gabarytowa (Rozmiar)	Długość osi małej elipsy równoważnej
<i>ConvexArea</i>	Gabarytowa (Rozmiar)	Pole powierzchni najmniejszego wielokąta wypukłego
<i>EquivDiameter</i>	Gabarytowa (Rozmiar)	Średnica koła o polu równym polu ziarna
<i>Eccentricity</i>	Kształt (Proporcje)	Mimośród elipsy (miara wydłużenia obiektu)
<i>Roundness</i>	Kształt (Proporcje)	Współczynnik zaokrąglenia i gładkości brzegu
<i>Compactness</i>	Kształt (Proporcje)	Zwartość (<i>EquivDiameter</i> / <i>MajorAxisLength</i>)
<i>Solidity</i>	Kształt (Proporcje)	Solidność (stosunek <i>Area</i> do <i>ConvexArea</i>)
<i>AspectRatio</i>	Kształt (Proporcje)	Współczynnik proporcji osi głównej do małej
<i>Extent</i>	Kształt (Proporcje)	Stosunek pola powierzchni do prostokąta otaczającego

2.2.2 Statystyki opisowe i podstawowa wizualizacja

W celu ilościowego opisu wybranych zmiennych wyznaczono podstawowe charakterystyki rozkładu empirycznego dla całego zbioru danych. Wyniki zestawiono w tabeli 2.2.

Tabela 2.2: Statystyki opisowe wybranych zmiennych numerycznych dla zbioru Dry Bean

Zmienna	Średnia	Mediana	Min.	Maks.	Odch. std.	Skośność
<i>Area</i>	53048.2	44652.0	20420.0	254616.0	29324.1	2.95
<i>Perimeter</i>	855.2	794.9	524.7	1985.4	214.3	1.63
<i>MajorAxisLength</i>	320.1	296.8	183.6	738.9	85.7	1.36
<i>MinorAxisLength</i>	202.3	192.3	122.5	460.2	45.0	2.23
<i>ConvexArea</i>	53768.2	45170.0	20684.0	263261.0	29774.9	2.94
<i>EquivDiameter</i>	253.1	238.5	161.3	569.4	59.2	1.87
<i>Eccentricity</i>	0.751	0.764	0.219	0.912	0.092	-1.06
<i>Roundness</i>	0.873	0.883	0.489	0.990	0.060	-1.41
<i>Compactness</i>	0.800	0.801	0.641	0.987	0.062	-0.04
<i>Solidity</i>	0.987	0.988	0.911	0.994	0.005	-2.57
<i>AspectRatio</i>	1.583	1.551	1.024	2.430	0.247	0.78
<i>Extent</i>	0.750	0.753	0.555	0.866	0.049	-0.90

Analiza statystyk opisowych wskazuje na występowanie silnej asymetrii prawostronnej w przypadku zmiennych gabarytowych (np. *Area*, *ConvexArea*), co wyraźnie obrazuje dodatnia, wysoka wartość współczynnika skośności. Wynika to bezpośrednio z obecności odmiany *BOMBAY*, której ziarna są wielokrotnie większe od pozostałych gatunków. Wizualizacja rozkładów za pomocą wykresów pudełkowych (ang. *boxplots*) oraz histogramów potwierdza, że odmiany różnią się drastycznie rozrzutem cech rozmiarowych, podczas gdy cechy kształtu (np. *Solidity*, *Roundness*) wykazują rozkłady bardziej skupione wokół swoich wartości centralnych, wykazując najczęściej asymetrię lewostronną.

2.2.3 Transformacje danych

Z uwagi na fakt, że cechy gabarytowe przyjmują wartości rzędu dziesiątek tysięcy, a bezwymiarowe współczynniki kształtu mieszczą się w wąskim przedziale (0, 1), bezpośrednie zastosowanie metod opartych na odległościach (jak SVM) lub analizy kowariancji (LDA/QDA) byłoby zdominowane przez zmienne o największych barierach skali. W celu ujednolicenia wpływu wszystkich cech na proces klasyfikacji zastosowano standaryzację (centrowanie i skalowanie), przekształcając każdą zmienną tak, aby jej średnia wynosiła 0, a odchylenie standardowe było równe 1. Ponadto dla zmiennych o najwyższym współczynniku skośności uzasadnione jest rozważenie transformacji logarytmicznej przed ostatecznym skalowaniem.

2.2.4 Braki danych

Zbiór danych poddano weryfikacji pod kątem występowania brakujących wartości (rekordów typu *NA* lub pustych komórek). Ze względu na to, że dane zostały wygenerowane automatycznie przez dedykowane oprogramowanie do segmentacji i ekstrakcji cech obrazu cyfrowego, zbiór jest kompletny i nie zawiera żadnych braków danych we wskazanych 12 zmiennych, co eliminuje konieczność stosowania algorytmów imputacji.

2.2.5 Obserwacje odstające

Fizyczna natura obiektów biologicznych dopuszcza występowanie anomalii rozwojowych (np. ziarna uszkodzone mechanicznie, zniekształcone lub niedorozwinięte). Identyfikacji obserwacji odstających dokonano przy użyciu reguły 1.5 rozstępu ćwiartkowego (IQR) na wykresach pudełkowych oraz wielowymiarowej analizy odległości Mahalanobisa. Obserwacje skrajnie nietypowe, będące najczęściej wynikiem błędów automatycznej segmentacji obrazu (np. złączenie dwóch nakładających się ziaren w jeden obiekt), zostały usunięte ze zbioru treningowego, aby zapobiec zaburzeniu granic decyzyjnych budowanych klasyfikatorów.

Rozdział 3

Opis metod

W niniejszym rozdziale przedstawiono metody klasyfikacji wykorzystane do rozwiązania problemu przypisania ziaren fasoli do odpowiednich odmian. Analizowany problem ma charakter klasyfikacji wieloklasowej, ponieważ zmienna objaśniana może przyjmować więcej niż dwie możliwe wartości.

Niech zmienna objaśniana Y oznacza klasę, czyli odmianę fasoli. W zbiorze *Dry Bean Dataset* zmienna ta przyjmuje jedną z siedmiu wartości:

$$Y \in \{SEKER, BARBUNYA, BOMBAY, CALI, DERMASON, HOROZ, SIRA\}.$$

Zmiennymi objaśniającymi są cechy geometryczne i morfologiczne opisujące pojedyncze ziarno fasoli. Dla pojedynczej obserwacji można je zapisać w postaci wektora:

$$X = (X_1, X_2, \dots, X_p),$$

gdzie p oznacza liczbę zmiennych objaśniających uwzględnionych w analizie.

Celem każdej z zastosowanych metod jest wyznaczenie reguły klasyfikacyjnej, która na podstawie wartości cech X przypisuje obserwację do jednej z klas Y . Innymi słowy, dla każdego ziarna fasoli model podejmuje decyzję, do której odmiany jest ono najbardziej podobne ze względu na swoje cechy geometryczne.

W analizie wykorzystano zmienne opisujące między innymi rozmiar, kształt, wydłużenie oraz regularność ziarna. Do cech związanych z rozmiarem należą na przykład *Area*, *Perimeter*, *ConvexArea*, *MajorAxisLength* oraz *MinorAxisLength*. Z kolei cechy takie jak *Eccentricity*, *Roundness*, *Compactness*, *AspectRatio* czy *Solidity* opisują przede wszystkim kształt i proporcje ziarna.

Zastosowane metody różnią się sposobem wyznaczania granic decyzyjnych między klasami. Część z nich, na przykład wielomianowa regresja logistyczna oraz LDA, zakłada liniowy charakter granic między klasami. Inne, takie jak QDA, drzewa decyzyjne, Random Forest czy SVM, pozwalają na bardziej złożone granice decyzyjne. Dzięki temu możliwe jest porównanie zarówno prostszych, bardziej interpretowalnych metod statystycznych, jak i metod bardziej elastycznych.

W dalszej części rozdziału opisano kolejno zastosowane metody klasyfikacji oraz sposób podejmowania przez nie decyzji klasyfikacyjnych.

3.1 Wielomianowa regresja logistyczna

Wielomianowa regresja logistyczna jest rozszerzeniem klasycznej regresji logistycznej na przypadek, w którym zmienna objaśniana przyjmuje więcej niż dwie kategorie. W analizowanym problemie metoda ta służy do oszacowania prawdopodobieństwa przynależności ziarna fasoli do każdej z rozważanych odmian.

Celem wielomianowej regresji logistycznej jest oszacowanie prawdopodobieństwa przynależności obserwacji do każdej z możliwych klas. Dla każdej obserwacji model wyznacza prawdopodobieństwa:

$$P(Y = k | X),$$

gdzie k oznacza jedną z klas. Obserwacja zostaje następnie przypisana do tej klasy, dla której przewidywane prawdopodobieństwo jest największe.

W modelu wielomianowej regresji logistycznej jedna z klas jest wybierana jako klasa referencyjna. Dla pozostałych klas modeluje się logarytm ilorazu szans względem tej klasy. Jeżeli jako klasę referencyjną oznaczymy klasę K , to dla każdej klasy $k = 1, \dots, K - 1$ model ma postać:

$$\log \left(\frac{P(Y = k | X)}{P(Y = K | X)} \right) = \beta_{0k} + \beta_{1k}X_1 + \beta_{2k}X_2 + \dots + \beta_{pk}X_p.$$

Oznacza to, że dla każdej klasy, z wyjątkiem klasy referencyjnej, estymowany jest osobny zestaw współczynników regresji. Współczynniki te opisują wpływ poszczególnych cech ziarna na względne prawdopodobieństwo przypisania obserwacji do danej klasy w porównaniu z klasą referencyjną.

Prawdopodobieństwa przynależności do poszczególnych klas można zapisać w postaci:

$$P(Y = k | X) = \frac{\exp(\beta_{0k} + \beta_{1k}X_1 + \dots + \beta_{pk}X_p)}{1 + \sum_{j=1}^{K-1} \exp(\beta_{0j} + \beta_{1j}X_1 + \dots + \beta_{pj}X_p)}$$

dla $k = 1, \dots, K - 1$, natomiast dla klasy referencyjnej:

$$P(Y = K | X) = \frac{1}{1 + \sum_{j=1}^{K-1} \exp(\beta_{0j} + \beta_{1j}X_1 + \dots + \beta_{pj}X_p)}.$$

W kontekście analizowanego zbioru danych model ten pozwala określić, jak cechy geometryczne ziarna wpływają na prawdopodobieństwo zaklasyfikowania go do konkretnej odmiany fasoli. Przykładowo, cechy związane z rozmiarem ziarna, takie jak *Area*, *Perimeter* czy *MajorAxisLength*, mogą mieć istotne znaczenie przy rozróżnianiu większych odmian fasoli od mniejszych. Z kolei cechy opisujące kształt, takie jak *Roundness*, *Compactness* czy *Eccentricity*, mogą pomagać w odróżnianiu odmian bardziej okrągłych od bardziej wydłużonych.

Klasyfikacja nowej obserwacji odbywa się poprzez obliczenie przewidywanego prawdopodobieństwa dla każdej klasy i wybór klasy o największej wartości tego prawdopodobieństwa:

$$\hat{Y} = \arg \max_k P(Y = k | X).$$

Wielomianowa regresja logistyczna jest metodą parametryczną i stosunkowo łatwą do interpretacji. Jej zaletą jest możliwość uzyskania nie tylko przewidywanej klasy, ale również prawdopodobieństw przynależności do każdej z klas. Dzięki temu można analizować, z jaką pewnością model przypisuje dane ziarno do konkretnej odmiany.

Metoda ta zakłada jednak, że zależność pomiędzy zmiennymi objaśniającymi a logarytmem ilorazu szans jest liniowa. W praktyce oznacza to, że model może gorzej radzić sobie w sytuacjach, gdy granice między klasami mają silnie nieliniowy charakter. W przypadku zbioru *Dry Bean* może to mieć znaczenie, ponieważ niektóre odmiany fasoli mogą być do siebie bardzo podobne pod względem wybranych cech morfologicznych.

W przeprowadzonej analizie wielomianowa regresja logistyczna została wykorzystana jako jedna z metod klasyfikacji statystycznej. Jej wyniki porównano z wynikami pozostałych metod na podstawie miar jakości klasyfikacji, takich jak macierz pomyłek, dokładność klasyfikacji oraz miary precyzji, czułości i wyniku F_1 .

3.2 LDA - Linear Discriminant Analysis

Liniowa analiza dyskryminacyjna, czyli LDA, jest jedną z klasycznych metod klasyfikacji statystycznej. Jej celem jest przypisanie obserwacji do jednej z dostępnych klas na podstawie wartości zmiennych objaśniających. W analizowanym zbiorze danych *Dry Bean Dataset* metoda ta służy do klasyfikacji ziaren fasoli do jednej z odmian na podstawie ich cech geometrycznych i morfologicznych.

LDA opiera się na założeniu, że rozkład zmiennych objaśniających w każdej klasie jest wielowymiarowym rozkładem normalnym. Dla klasy k można to zapisać jako:

$$X | Y = k \sim N(\mu_k, \Sigma),$$

gdzie μ_k oznacza wektor średnich cech dla klasy k , natomiast Σ oznacza wspólną macierz kowariancji dla wszystkich klas.

Istotnym założeniem metody LDA jest więc to, że wszystkie klasy mają taką samą macierz kowariancji. Oznacza to, że chmury punktów odpowiadające poszczególnym klasom mogą mieć różne środki, ale zakłada się, że mają podobny kształt i podobne rozproszenie.

Klasyfikacja w metodzie LDA odbywa się na podstawie funkcji dyskryminacyjnych. Dla każdej klasy k wyznacza się wartość:

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k,$$

gdzie π_k oznacza prawdopodobieństwo a priori przynależności obserwacji do klasy k .

Nowa obserwacja x zostaje przypisana do tej klasy, dla której funkcja dyskryminacyjna przyjmuje największą wartość:

$$\hat{Y} = \arg \max_k \delta_k(x).$$

Ponieważ funkcja dyskryminacyjna $\delta_k(x)$ jest funkcją liniową względem wektora cech x , granice decyzyjne między klasami są liniowe. Oznacza to, że metoda LDA najlepiej sprawdza się wtedy, gdy klasy można rozdzielić za pomocą prostych, liniowych granic w przestrzeni cech.

W kontekście zbioru *Dry Bean* metoda LDA próbuje znaleźć takie kombinacje liniowe cech, które najlepiej rozdzielają poszczególne odmiany fasoli. Przykładowo, cechy związane z rozmiarem ziarna, takie jak *Area*, *Perimeter* czy *MajorAxisLength*, mogą pomagać w oddzieleniu większych odmian od mniejszych. Z kolei cechy opisujące kształt, takie jak *Roundness*, *Compactness* czy *Eccentricity*, mogą mieć znaczenie przy rozróżnianiu odmian bardziej okrągłych od bardziej wydłużonych.

Zaletą metody LDA jest jej prostota, interpretowalność oraz stosunkowo niewielka złożoność obliczeniowa. Metoda ta pozwala również analizować, które kierunki w przestrzeni cech najlepiej rozdzielają klasy. Wadą LDA są natomiast dość silne założenia dotyczące rozkładów danych, w szczególności założenie o normalności zmiennych w klasach oraz o wspólnej macierzy kowariancji.

W przypadku zbioru *Dry Bean* założenie o wspólnej macierzy kowariancji może być ograniczeniem, ponieważ różne odmiany fasoli mogą charakteryzować się innym rozproszeniem cech. Na przykład jedna odmiana może być bardzo jednorodna pod względem kształtu i rozmiaru, podczas gdy inna może wykazywać większą zmienność morfologiczną. Mimo to LDA stanowi użyteczną metodę porównawczą, szczególnie ze względu na swoją klasyczną interpretację statystyczną i prostą postać granic decyzyjnych.

3.3 QDA - Quadratic Discriminant Analysis

Kwadratowa analiza dyskryminacyjna, czyli QDA, jest metodą klasyfikacji statystycznej blisko związaną z liniową analizą dyskryminacyjną. Podobnie jak LDA, metoda QDA zakłada, że rozkład zmiennych objaśniających w każdej klasie jest wielowymiarowym rozkładem normalnym. Różnica polega jednak na tym, że QDA nie wymaga, aby wszystkie klasy miały tę samą macierz kowariancji.

Dla klasy k zakłada się, że:

$$X | Y = k \sim N(\mu_k, \Sigma_k),$$

gdzie μ_k oznacza wektor średnich cech dla klasy k , natomiast Σ_k oznacza macierz kowariancji charakterystyczną dla tej klasy.

W przeciwieństwie do LDA, w metodzie QDA każda klasa może mieć własną strukturę zmienności. Oznacza to, że klasy mogą różnić się nie tylko położeniem w przestrzeni cech, ale również kształtem i rozproszeniem chmur punktów. Jest to szczególnie istotne wtedy, gdy analizowane grupy nie mają podobnej wariancji lub gdy granice między nimi nie są liniowe.

Funkcja dyskryminacyjna dla klasy k w metodzie QDA ma postać:

$$\delta_k(x) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) + \log \pi_k,$$

gdzie π_k oznacza prawdopodobieństwo a priori przynależności obserwacji do klasy k .

Nowa obserwacja x jest klasyfikowana do tej klasy, dla której funkcja dyskryminacyjna osiąga największą wartość:

$$\hat{Y} = \arg \max_k \delta_k(x).$$

Ze względu na obecność składnika kwadratowego

$$(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k),$$

granice decyzyjne w metodzie QDA są na ogół krzywoliniowe. Oznacza to, że QDA jest metodą bardziej elastyczną niż LDA i może lepiej dopasować się do sytuacji, w której klasy są rozdzielone w sposób nieliniowy.

W kontekście zbioru *Dry Bean* metoda QDA może być przydatna, ponieważ różne odmiany fasoli mogą mieć odmienne rozkłady cech. Przykładowo, odmiana *BOMBAY* może być stosunkowo łatwa do odróżnienia ze względu na większy rozmiar ziaren, natomiast odmiany takie jak *DERMASON* i *SIRA* mogą być do siebie bardziej podobne i częściowo nakładać się w przestrzeni cech. W takiej sytuacji możliwość tworzenia nieliniowych granic decyzyjnych może poprawić jakość klasyfikacji.

Zaletą QDA jest większa elastyczność w porównaniu z LDA. Metoda ta może lepiej radzić sobie w przypadku klas o różnym rozproszeniu i różnych kształtach rozkładów. Wadą jest natomiast większa liczba estymowanych parametrów, ponieważ dla każdej klasy osobno estymowana jest macierz kowariancji. Może to prowadzić do mniej stabilnych wyników, szczególnie wtedy, gdy liczba obserwacji w niektórych klasach jest niewielka lub gdy zmienne objaśniające są silnie skorelowane.

W zbiorze *Dry Bean* wiele cech opisujących ziarna jest ze sobą naturalnie powiązanych. Przykładowo, większe ziarna mają zwykle większe wartości zmiennych takich jak *Area*, *Perimeter*, *MajorAxisLength* czy *ConvexArea*. Silna współzależność zmiennych może wpływać na stabilność estymacji macierzy kowariancji w metodzie QDA.

Podsumowując, QDA można traktować jako bardziej elastyczne rozszerzenie LDA. LDA zakłada wspólną macierz kowariancji dla wszystkich klas i prowadzi do liniowych granic decyzyjnych, natomiast QDA dopuszcza osobne macierze kowariancji dla każdej klasy i umożliwia tworzenie granic krzywoliniowych. W przeprowadzonej analizie obie metody zostały wykorzystane w celu porównania skuteczności klasycznych metod dyskryminacyjnych w problemie klasyfikacji odmian fasoli.

3.4 Naive Bayes

Naiwny klasyfikator Bayesa jest probabilistyczną metodą klasyfikacji opartą na twierdzeniu Bayesa. Celem metody jest wyznaczenie prawdopodobieństwa przynależności obserwacji do każdej z klas na podstawie wartości zmiennych objaśniających, a następnie przypisanie obserwacji do klasy o największym prawdopodobieństwie a posteriori.

Zgodnie z twierdzeniem Bayesa prawdopodobieństwo przynależności obserwacji o wektorze cech X do klasy k można zapisać jako:

$$P(Y = k | X) = \frac{P(X | Y = k)P(Y = k)}{P(X)}.$$

W powyższym wzorze $P(Y = k | X)$ oznacza prawdopodobieństwo a posteriori przynależności obserwacji do klasy k , $P(X | Y = k)$ oznacza prawdopodobieństwo zaobserwowania danego zestawu cech w klasie k , natomiast $P(Y = k)$ jest prawdopodobieństwem a priori wystąpienia klasy k .

Ponieważ mianownik $P(X)$ jest taki sam dla wszystkich klas, przy klasyfikacji można porównywać jedynie wartości licznika:

$$P(Y = k | X) \propto P(X | Y = k)P(Y = k).$$

Nowa obserwacja zostaje przypisana do tej klasy, dla której powyższe wyrażenie przyjmuje największą wartość:

$$\hat{Y} = \arg \max_k P(X | Y = k)P(Y = k).$$

Nazwa metody wynika z jej podstawowego założenia, nazywanego założeniem naiwnym. Zakłada się mianowicie, że zmienne objaśniające są warunkowo niezależne przy znanej klasie. Oznacza to, że po ustaleniu klasy $Y = k$ każda cecha X_j jest traktowana jako niezależna od pozostałych cech. Wtedy prawdopodobieństwo $P(X | Y = k)$ można zapisać jako iloczyn prawdopodobieństw dla poszczególnych zmiennych:

$$P(X | Y = k) = P(X_1, X_2, \dots, X_p | Y = k) \approx \prod_{j=1}^p P(X_j | Y = k).$$

W konsekwencji reguła klasyfikacyjna przyjmuje postać:

$$\hat{Y} = \arg \max_k P(Y = k) \prod_{j=1}^p P(X_j | Y = k).$$

W analizowanym zbiorze *Dry Bean Dataset* zmienne objaśniające mają charakter ilościowy, ponieważ opisują geometryczne i morfologiczne cechy ziaren fasoli. Z tego względu w praktyce stosuje się najczęściej gaussowską wersję naiwnego klasyfikatora Bayesa. Zakłada ona, że rozkład każdej zmiennej objaśniającej w obrębie danej klasy jest rozkładem normalnym:

$$X_j | Y = k \sim N(\mu_{jk}, \sigma_{jk}^2),$$

gdzie μ_{jk} oznacza średnią wartość cechy X_j w klasie k , natomiast σ_{jk}^2 oznacza wariancję tej cechy w klasie k .

Dla każdej klasy oraz każdej cechy estymowane są więc osobne parametry rozkładu normalnego. Następnie dla nowej obserwacji model oblicza, jak prawdopodobne są zaobserwowane wartości cech przy założeniu, że obserwacja pochodzi z danej klasy. Na tej podstawie wyznaczane jest prawdopodobieństwo przynależności do każdej odmiany fasoli.

W kontekście klasyfikacji ziaren fasoli metoda Naive Bayes sprawdza więc, dla której odmiany najbardziej prawdopodobne są obserwowane wartości takich cech jak *Area*, *Perimeter*, *MajorAxisLength*, *MinorAxisLength*, *Roundness*, *Compactness* czy *Eccentricity*. Przykładowo, jeżeli dane ziarno ma duże wartości cech związanych z rozmiarem, model może przypisać mu większe prawdopodobieństwo przynależności do odmiany charakteryzującej się większymi ziarnami.

Zaletą naiwnego klasyfikatora Bayesa jest prostota, niewielka złożoność obliczeniowa oraz możliwość uzyskania probabilistycznej interpretacji wyników. Metoda ta może być stosowana jako punkt odniesienia dla bardziej złożonych klasyfikatorów, ponieważ jest szybka i łatwa do implementacji.

Głównym ograniczeniem metody jest założenie warunkowej niezależności cech. W przypadku zbioru *Dry Bean* założenie to jest dość silne, ponieważ wiele zmiennych opisujących ziarno jest ze sobą naturalnie powiązanych. Przykładowo, większe ziarna mają zwykle jednocześnie większe wartości zmiennych takich jak *Area*, *Perimeter*, *MajorAxisLength* czy *ConvexArea*. Podobnie cechy opisujące kształt, takie jak *Roundness*, *Compactness* i *Eccentricity*, również mogą być ze sobą skorelowane.

Z tego powodu naiwny klasyfikator Bayesa może nie wykorzystywać w pełni zależności występujących między zmiennymi. Mimo to metoda została uwzględniona w analizie jako klasyczny probabilistyczny klasyfikator, którego wyniki można porównać z metodami bardziej elastycznymi, takimi jak QDA, Random Forest czy SVM.

3.5 Random Forest

Lasy losowe (ang. *Random Forest*) to zaawansowany algorytm uczenia maszynowego należący do rodziny metod zespołowych (ang. *ensemble methods*). Podstawą tej metody jest konstruowanie wielu niezależnych drzew decyzyjnych w fazie trenowania modelu. Ostateczna decyzja klasyfikacyjna podejmowana jest poprzez agregację wyników wszystkich pojedynczych drzew za pomocą głosowania większościowego – obserwacja jest przypisywana do klasy, którą wskazała najliczniejsza grupa drzew decyzyjnych.

Siłą tej metody i her odporność na zjawisko przeuczenia (ang. *overfitting*) wynikają z podwójnego zastosowania losowości. Po pierwsze, każde z drzew jest uczone na nieco innym podzbiorze danych treningowych, pobieranym ze zwracaniem w ramach procedury tzw. agregacji bootstrapowej (ang. *bagging*). Po drugie, w każdym węźle drzewa, podczas wyboru optymalnego kryterium podziału, algorytm rozważa jedynie losowo wybrany podzbiór wszystkich dostępnych zmiennych objaśniających (zazwyczaj o rozmiarze $\sqrt{p}$, gdzie p to całkowita liczba cech).

Podział węzła m w pojedynczym drzewie dokonywany jest poprzez wyznaczenie takiego parametru i punktu podziału, który maksymalizuje spadek nieczystości (ang. *impurity*). Nieczystość węzła dla klasyfikacji wieloklasowej najczęściej opisuje się za pomocą indeksu Giniego $G(m)$ lub entropii $H(m)$, zdefiniowanych jako:

$$G(m) = \sum_{k=1}^K \hat{p}_{mk}(1 - \hat{p}_{mk}) \quad (3.1)$$

$$H(m) = - \sum_{k=1}^K \hat{p}_{mk} \log_2 \hat{p}_{mk} \quad (3.2)$$

gdzie $\hat{p}_{mk}$ oznacza proporcję obserwacji klasy k ($k = 1, \dots, K$) w węźle m .

W analizie zbioru *Dry Bean*, gdzie zmienne objaśniające (jak *Area*, *Perimeter* czy *ConvexArea*) charakteryzują się bardzo silną korelacją liniową, metoda lasów losowych wykazuje dużą przewagę. Losowy dobór zmiennych w węzłach zapobiega zdominowaniu struktury wszystkich drzew przez jedną, najsilniej różnicującą cechę rozmiaru. Wymusza to na pojedynczych klasyfikatorach poszukiwanie reguł decyzyjnych także w subtelniejszych parametrach kształtu (takich jak *ShapeFactor1* czy *Solidity*), co znacząco poprawia elastyczność i moc uogólniania całego modelu.

3.6 SVM - metoda wektorów nośnych

Maszyna wektorów nośnych (ang. *Support Vector Machine*, SVM) to algorytm, którego głównym celem jest znalezienie w wielowymiarowej przestrzeni cech takiej hiperpowierzchni decyzyjnej, która możliwie najlepiej rozdziela obserwacje należące do różnych klas. Optymalna granica definiowana jest jako ta, która maksymalizuje tzw. margines, czyli minimalną odległość pomiędzy wyznaczoną hiperpowierzchnią a najbliższymi jej punktami treningowymi z każdej klasy. Punkty leżące dokładnie na krawędziach tego marginesu określane są mianem wektorów nośnych i to wyłącznie one determinują położenie granicy.

W ogólnym przypadku, gdy dane nie są idealnie separowalne liniowo, wprowadza się tzw. zmienne dopełniające $\xi_i \geq 0$ (ang. *slack variables*), dopuszczające pewne błędy klasyfikacji na zbiorze treningowym. Konstrukcja optymalnego klasyfikatora sprowadza się wówczas do rozwiązania zadania optymalizacyjnego z tzw. miękkim marginesem (ang. *soft margin*):

$$\min_{w, b, \xi} \left(\frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \right) \quad (3.3)$$

przy zachowaniu warunków ograniczających:

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, N \quad (3.4)$$

gdzie w to wektor wag hiperpłaszczyzny, b to wyraz wolny, $y_i \in \{-1, 1\}$ oznacza etykietę klasy, a parametr $C > 0$ kontroluje kompromis pomiędzy szerokością marginesu a karą za błędy treningowe.

Głównym atutem metody SVM w złożonych zadaniach klasyfikacyjnych jest możliwość zastosowania tzw. sztuczki jądrowej (ang. *kernel trick*). Technika ta pozwala na niejawne rzutowanie oryginalnych zmiennych objaśniających do przestrzeni o wyższym wymiarze za pomocą funkcji jądra $K(x_i, x_j) = \langle \Phi(x_i), \Phi(x_j) \rangle$. W niniejszym projekcie wykorzystano radialną funkcję bazową (jądro RBF / gaussowskie), zdefiniowaną jako:

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (3.5)$$

gdzie $\gamma > 0$ jest parametrem określającym promień wpływu pojedynczej obserwacji wspierającej.

Dla ziaren fasoli, odmiany takie jak *DERMASON* i *SIRA* bywają silnie zbliżone wizualnie, co objawia się gęstym nakładaniem się chmur ich punktów w szesnastowymiarowej przestrzeni cech. Elastyczność maszyny wektorów nośnych z nieliniowym jądrem RBF pozwala na zdefiniowanie płynnych, zakrzywionych granic obszarów decyzyjnych, co pozwala skutecznie omijać ograniczenia klasycznej liniowej analizy dyskryminacyjnej.

3.7 Przegląd literatury dotyczącej metod

Problematyka zautomatyzowanej oceny i klasyfikacji produktów rolniczych z wykorzystaniem wizji komputerowej jest intensywnie rozwijana w literaturze naukowej. Sam oryginalny zbiór danych *Dry Bean Dataset* został opracowany i opublikowany w pracy Koklu i Ozkana [?]. Autorzy skutecznie pozyskali parametry morfologiczne z obrazów ziaren, a następnie wykorzystali je do porównania wydajności klasyfikatorów takich jak sztuczne sieci neuronowe (MLP), maszyny wektorów nośnych oraz

k-najbliższych sąsiadów. Ich badania dowiodły, że parametry geometryczne są wystarczające do zbudowania wysoce skutecznych modeli różnicujących gatunki fasoli.

Podstawy pod wykorzystane w analizie nowoczesne algorytmy uczenia maszynowego były formowane w pracach kładących podwaliny pod współczesne statystyczne analizy wielowymiarowe. Metoda maszyn wektorów nośnych (SVM) z mechanizmem obsługi danych zaszumionych (tworząca fundamenty sformułowanego w równaniach (3.3)–(3.4) miękkiego marginesu) została sformalizowana w przełomowej pracy Cortesa i Vapnika z 1995 roku [?]. Rozwiązało to problem klasyfikacji zbiorów liniowo nieseparowalnych, co znacząco rozszerzyło dziedziny aplikacji tego modelu. Z kolei idea i ścisły dowód na to, że wstrzykiwanie losowości do zespołów klasyfikatorów znacząco redukuje błąd generalizacji, została opublikowana w kanonicznej już pracy Leo Breimana z 2001 roku [?], wprowadzającej algorytm *Random Forest*.

Użyte jako punkt odniesienia klasyczne metody, takie jak wielomianowa regresja logistyczna oraz analiza dyskryminacyjna, opierają się na dobrze ugruntowanej teorii probabilistycznej i wciąż są powszechnie stosowane w obszarach wymagających bezpośredniej interpretacji estymowanych współczynników wpływu cech na przynależność klasową.

Rozdział 4

Wyniki

Tabela 4.1: Macierz pomyłek dla wielomianowej regresji logistycznej

	BARBUNYA	BOMBAY	CALI	DERMASON	HOROS	SEKER	SIRA
BARBUNYA	358	0	26	0	2	4	7
BOMBAY	0	157	0	0	0	0	0
CALI	14	1	463	0	10	0	1
DERMASON	0	0	0	986	5	13	60
HOROS	1	0	12	5	540	0	21
SEKER	2	0	0	9	0	585	13
SIRA	3	0	3	93	4	8	680

Tabela 4.2: Dokładność klasyfikacji dla wielomianowej regresji logistycznej

Metoda	Accuracy
Wielomianowa regresja logistyczna	0.9224

Tabela 4.3: Miary jakości klasyfikacji dla wielomianowej regresji logistycznej

Klasa	Precision	Recall	F1
BARBUNYA	0.9471	0.9018	0.9239
BOMBAY	0.9937	1.0000	0.9968
CALI	0.9187	0.9468	0.9325
DERMASON	0.9021	0.9267	0.9142
HOROS	0.9626	0.9326	0.9474
SEKER	0.9590	0.9606	0.9598
SIRA	0.8696	0.8597	0.8646

4.1 Mierniki

4.2 Sposób walidacji

Rozdział 5

Przykład użycia modeli na stworzonych sztucznie obserwacjach

Bibliografia

[1] xx, x. (xxx). *xxx*. xxx. xxxx